RL для вызова функций

HW5 · GRPO на ToolACE · оценка на supplied BFCL

1. Задача

Улучшить function calling Qwen/Qwen3.5-2B только методами RL. Итоговая метрика — overall на фиксированном BFCL из 350 примеров.

2. Данные

В ToolACE 11 300 диалогов. Сначала они разделены по dialog_id в пропорции 90/10, затем раскручены: каждый ответ assistant после user стал отдельным RL-примером. Части одного диалога не попадают в разные сплиты.

После фильтрации prompt до 2048 и target до 512 токенов: 10 745 train и 1 191 validation примеров; 2 051 без вызова, 5 813 с одним вызовом, 4 072 с несколькими.

3. Награда и общие параметры

Для вызовов: R = 0.10 * format + 0.25 * F1(function set) + 0.65 * argument score. Проверяются разметка Qwen, набор функций и типизированные аргументы. Для no-call награда 1 только при отсутствии вызова. Контрольная награда — 1 лишь за полное совпадение.

Во всех основных запусках: 300 шагов, batch 4, GA 4, lr 1e-6, cosine scheduler, warmup 3%, BF16, одна A100, seed 42. BFCL оценивается с одинаковым детерминированным декодированием.

4. Конфигурации

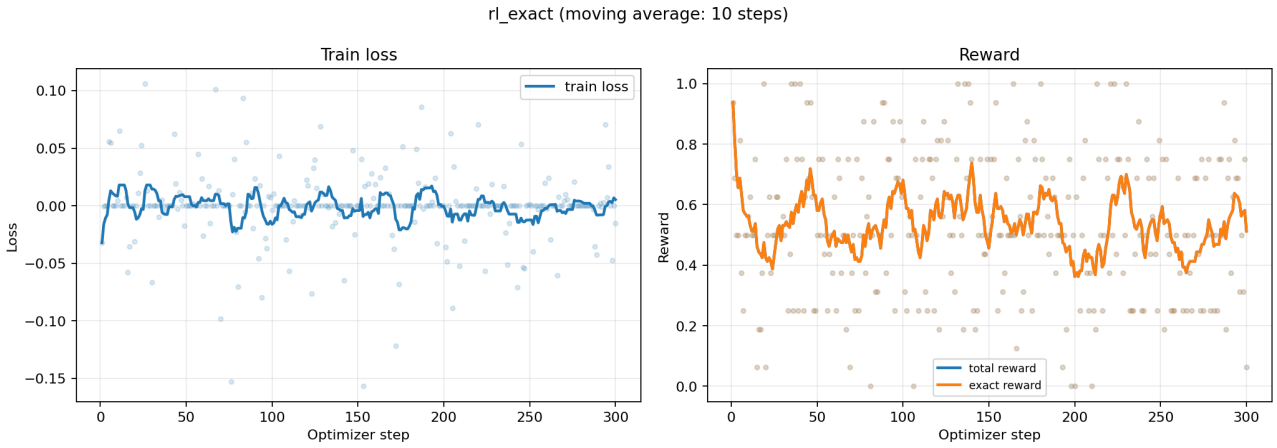
Запуск	Изменение	Награда	G	T	Шаг
rl_exact	разреженный контроль	точное совпадение	4	0.7	300
rl_shaped	частичная награда	составная	4	0.7	300
rl_shaped_g8	больше вариантов	составная	8	0.7	300
rl_shaped_temp1	выше разнообразие генераций	составная	4	1.0	300
rl_shaped_temp1_multicall	дублирование multi-call	составная	4	1.0	300

Технические пробы: vLLM ускорил rollout; activation checkpointing на этой конфигурации замедлял обучение. При T=1.0 меньше групп имели нулевой advantage.

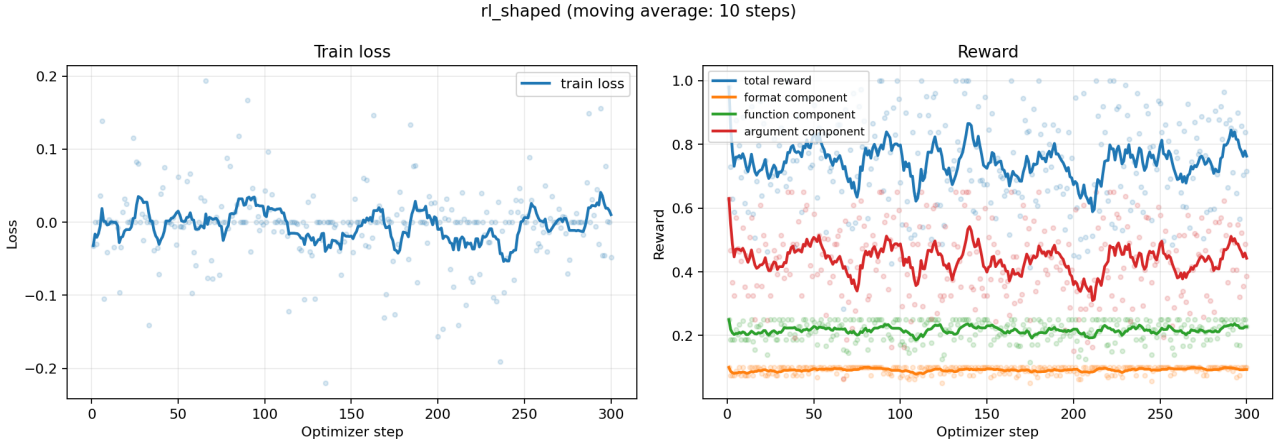
5. Графики loss и reward

Точки — шаги оптимизатора; линия — скользящее среднее по 10 шагам.

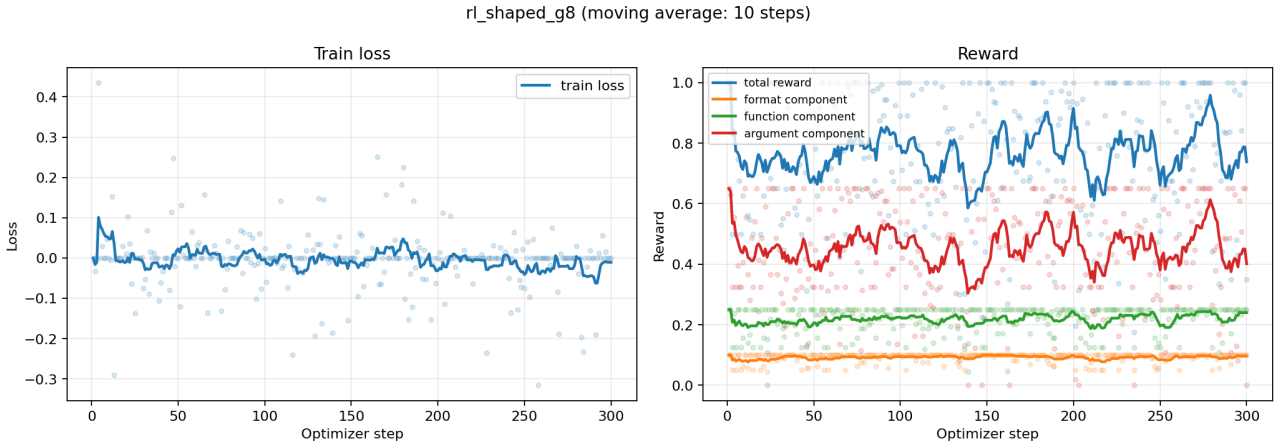
rl_exact



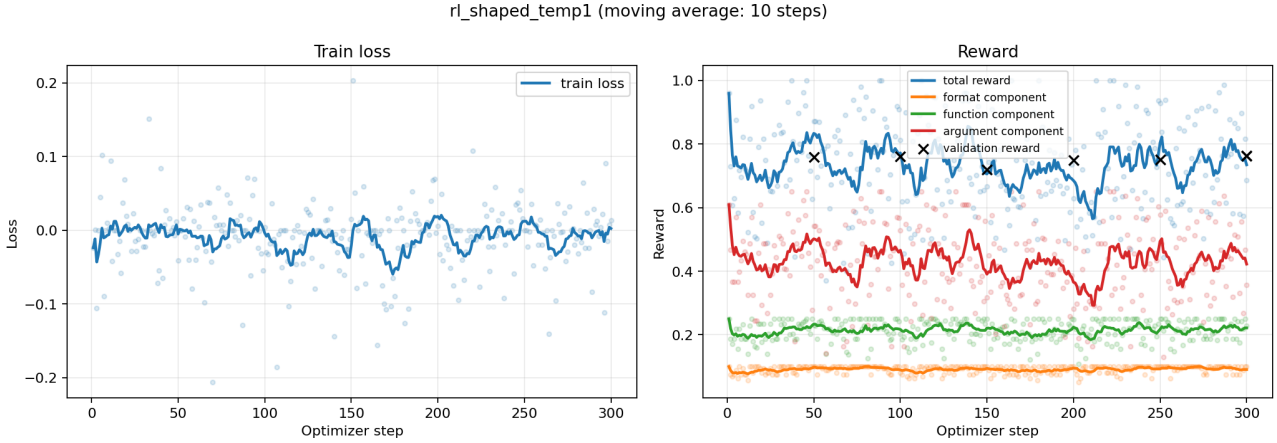
rl_shaped



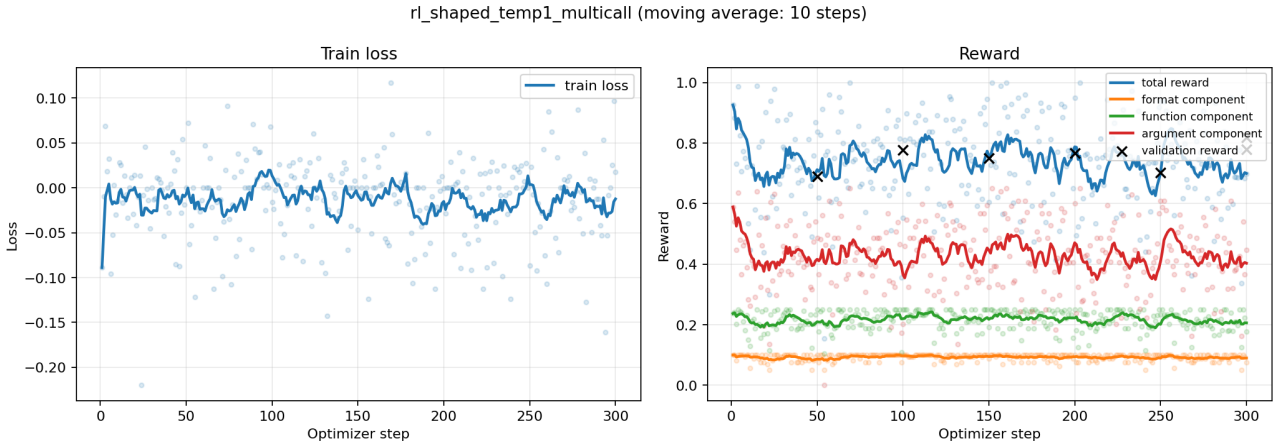
rl_shaped_g8



rl_shaped_temp1

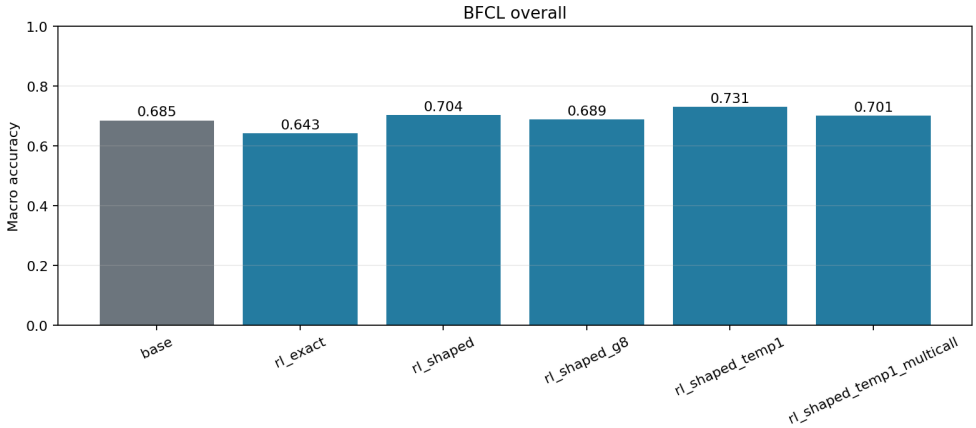


rl_shaped_temp1_multicall



6. BFCL

Запуск	Overall	Simple	Multiple	Parallel	Par+Mult	Irrel.
Base	0.685	0.680	0.787	0.560	0.800	0.600
rl_exact	0.643	0.620	0.713	0.500	0.600	0.780
rl_shaped	0.704	0.660	0.760	0.520	0.800	0.780
rl_shaped_g8	0.689	0.660	0.767	0.520	0.780	0.720
rl_shaped_temp1	0.731	0.700	0.793	0.580	0.800	0.780
rl_shaped_temp1_multicall	0.701	0.660	0.787	0.520	0.740	0.800



Лучший запуск — rl_shaped_temp1: 0.731 против 0.685 у base.

7. Выводы

Почему такая награда? Exact match слишком редкая. Shaped reward даёт сигнал за правильный формат, функцию и аргументы.

Самое сильное изменение. T=0.7 → 1.0: сравнение rl_shaped и rl_shaped_temp1 изолирует только этот фактор. BFCL: 0.704 → 0.731.

Награда и BFCL. Не совпадают полностью: G=8 и oversampling multi-call не улучшили BFCL. Награда считается на stochastic ToolACE rollout, BFCL — на других схемах инструментов.

Одинаковые награды. Если все G ответов имеют одну награду, advantage равен нулю; группа не даёт GRPO-сигнала.

Ошибки лучшей модели. Лишний вызов: irrelevance_233 — погода для вопроса о USD/GBP. Пропущенные: parallel_31 — текст вместо двух history_fact.fetch. Аргументы: parallel_105 — в последнем вызове temp=350 вместо 300.

Итог: shaped reward и T=1.0 улучшили BFCL; sparse reward, G=8 и дублирование multi-call — нет.